

上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

芯片发电技术基础与应用结题报告



项目名称: 基于热电芯片的多波段天空辐射观测系统

学生姓名: 冯峻 黄宇隽 李泽埔 欧阳凯泽 潘立扬

学生学号: 523031910148 (冯峻)

专 业: 微电子科学与工程

指导教师: 胡志宇 蔡星汉 姚正同

学院 (系): 集成电路学院

填写说明

1. 项目小组必须认真撰写《芯片发电技术基础与应用结题报告》。
2. 项目小组应在指导教师的指导下认真、实事求是地填写各项内容。
文字表达要明确、严谨，语句通顺，条理清晰。外来语要同时用原文和中文表达，第一次出现的缩写词，须注出全称。
3. 参考文献的书写请参照《上海交通大学本科生毕业设计（论文）撰写规范》。
4. 结题报告总字数应满足本课程要求。
5. 请用宋体小四号字体填写。



芯片发电技术基础与应用结题报告

项目名称	基于热电芯片的多波段天空辐射观测系统
摘要:	

项目研究目的和意义：

研究目的：

本项目旨在基于热电芯片传感器阵列搭建一套可连续运行的多波段天空辐射采集与分析系统，实现数据硬件采集、数据处理、模型预测与可视化展示于一体的综合实验系统。具体研究目的包括：

1) 实现多波段天空辐射的分离与稳定采集

基于热电芯片对辐射能量敏感、结构简单、成本低廉的特点，结合多种窄带滤光片，构建覆盖紫外、可见光及近红外波段的 8 通道辐射采集阵列，实现对不同波段太阳辐射强度的同步观测。

2) 搭建自动化、高频率、高精度的数据采集系统

以 Raspberry Pi 为控制核心，结合 ADS1115 高精度 ADC 模块，通过 Python 脚本实现多通道数据的自动采集、频率控制，减少人工干预，提高实验的可重复性与长期运行稳定性。

3) 多通道辐射强度的时间序列预测

针对辐射数据噪声大、短时波动明显但长期变化相对平稳的特点，引入 GRU 与 LSTM 等循环神经网络模型，并合理引入多种数据降噪与采样策略，建立能够对多通道辐射强度进行短期预测的时间序列模型。

4) 构建实时辐射监测与预测的可视化系统

通过前后端协同设计，实现辐射数据的实时传输、模型推理与结果图形化，直观呈现历史数据、预测曲线及多通道对比结果，提升系统的工程完整性与可用性。

5) 构建天空图像处理系统

同步采集天空图像，并利用传统图像处理方法提取云量、纹理和边缘等指标，用于辅助解释辐射数据中的异常波动，为后续多模态分析奠定基础。

研究意义：

1) 多波段采集天空辐射的意义

辐射研究之所以与天气密切相关，是因为多波段辐射对云与水汽变化具有天然高敏感度。不同波段范围的辐射特性不同：紫外波段进入大气时会被臭氧层吸收，可见光 波段，瑞利散射使得天空呈现蓝色，红外波段被水汽和CO₂吸收，区分不同波段的辐射贡献，可以帮助我们了解大气吸收、散射、辐射的物理机制。

此外，在环境科学、遥感、气象观测中，区分波段能量有助于分析地表能量收支平衡、校准卫星遥感数据、研究云层、气溶胶、污染对不同波段辐射的影响。有助于我们研究地表能量平衡与检测环境变化。

在实时获取天空图像后，我们还能进一步结合辐射强度的数据进行空气质量的检测，温度、湿度以及云量估算。

2) 利用时间序列模型进行多通道辐射强度短时/长时预测的意义

天空辐射强度不仅随昼夜周期呈现明显的长期变化趋势，同时也会受到云层移动、遮挡、水汽变化等因素影响，在短时间尺度上产生较大的波动。因此，仅依赖历史观测数据进行事后分析，难以及时刻画辐射变化的动态特性，而引入时间序列预测模型具有重要意义。

一方面，基于时间序列模型的辐射预测能够对未来一段时间内的辐射变化趋势进行提前估计，为气象监测、光伏发电功率预测以及相关实验决策提供参考依据。特别是在多波段观测条件下，不同波段辐射对云、水汽和大气成分的响应存在差异，通过多通道联合预测，有助于更全面地刻画天空辐射的演化行为。

另一方面，辐射数据具有噪声大、采样频率高、物理变化与测量扰动交织等特点，传统的解析建模方法难以准确描述其时序特性。LSTM、GRU 等循环神经网络能够自动从历史数据中学习长期依赖关系和潜在变化规律，为复杂物理过程提供一种数据驱动的建模思路。本项目通过引入多种降噪与采样策略，并对不同模型结构进行对比验证，探索了时间序列模型在辐射数据预测任务中的适用性与优势。

此外，将预测模型嵌入实时采集系统中，实现“观测—预测—验证”的闭环流程，有助于提升实验系统的智能化水平，也为后续开展异常检测、数据质量评估以及多模态联合建模提供了基础支撑。

研究方法和研究思路：

本项目整体研究思路遵循“物理观测 → 数据处理 → 智能建模 → 实时呈现”的技术路线，将硬件传感系统、时间序列预测模型与可视化交互系统有机结合，形成一个完整、可连续运行的多波段天空辐射观测与分析系统。具体研究方法主要围绕以下三个板块展开。设计框图参见图 1。

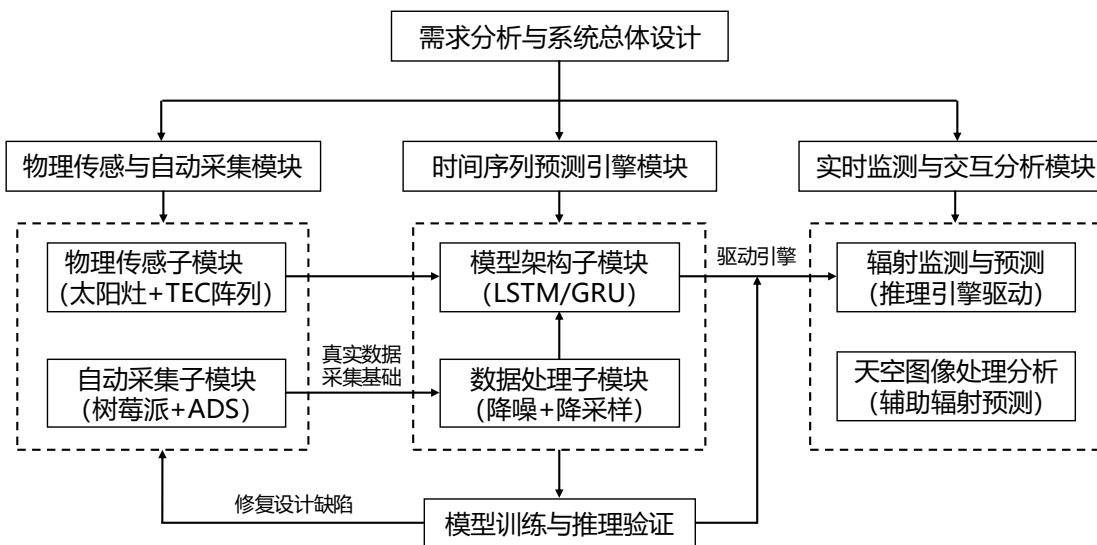


图 1 系统流程设计框图

1) 物理传感与自动采集模块

在物理传感子模块，本项目首先构建了多波段天空辐射的传感与采集系统。系统以太阳灶为聚光装置，利用其在焦点附近形成的高强度辐射区域，提高辐射信号强度与信噪比。在焦点区域周围，结合太阳灶焦斑近似高斯分布的特性，对 8 枚热电芯片（TEC）进行阵列化布置（环绕在焦点周围，并且在光轴方向上错开一段距离以均匀化受热情况），并通过在各通道前端配置不同波段范围的滤光片，实现对紫外、可见光及近红外等多个波段辐射的分离采集。

在自动采集子模块，系统采用 4 块 ADS1115 高精度模数转换器（ADC），每块 ADC 负责两个 TEC 通道的电压采集，实现 8 通道辐射信号的同步测量。采集控制以 Raspberry Pi 为核心，通过 Python 脚本调用 board、busio 以及 adafruit_ads1x15 等库，对 ADC 进行初始化配置、采样频率控制和数据读取。采集到的原始电压数据按时间顺序自动存储，采样频率可自由设置，初期设置为 10s 一次，后期为了丰富数据量提升到 5s 一次。通过该硬件与软件相结合的方式，我们完成了一套自动化、高频率、多通道的天空辐射数据采集系统。

2) 时间序列预测引擎模块

在完成稳定的数据采集后，针对多波段辐射数据噪声大、短时波动明显但长期变化相对平稳的特点，本项目进一步开展了时间序列预测模型的构建与验证工作。整体思路是先对原始数据进行分析与预处理，再引入合适的时间序列预测模型进行建模。在模型的预测过程中，我们也会根据数据和预测情况及时发现物理传感与自动采集模块的设计缺陷，并作出及时修复，确保数据的准确性与完整性。

在数据预处理子模块，本模块中的数据预处理阶段的优化程度将对时间序列的预测效果造成重大影响，针对热电芯片单点测量和环境扰动带来的高频噪声，我们

设计开发并比较了多种数据降噪与采样策略，包括主动限幅、滑动平均以及降采样方法，用以抑制异常跳变和高频噪声成分，同时尽量保留辐射强度的物理变化趋势。

在**模型架构搭建子模块**，模型选择方面，首先采用参数量较小、训练速度较快的 GRU 模型进行快速原型验证，以评估不同数据处理策略对预测效果的影响；在此基础上，进一步引入 LSTM 模型作为核心预测模型，用于捕捉辐射数据中的长期依赖关系。通过在不同数据集配置下进行训练、验证与测试，对模型的预测精度和稳定性进行系统评估，从而确定适用于本项目辐射数据特性的预测方案。

3) 实时监测与交互分析模块

为了将数据采集与预测结果直观呈现，并提升系统的工程完整性与可操作性，本项目进一步构建了两个相互独立但功能互补的图形化用户界面（GUI）系统。

其一是**基于辐射数据的实时监测与预测子模块**。该系统采用“Raspberry Pi 前端 + 主机后端”的架构：前端负责实时采集 8 通道辐射数据，并通过网络通信将数据发送至主机；后端在接收数据后，调用已训练完成的时间序列预测推理引擎进行实时预测，并将历史数据、预测结果以及多通道对比曲线动态展示在界面中，从而实现辐射观测与预测的实时联动。

其二是**基于图像数据的天空图像处理与分析子模块**。该系统以同步采集的天空图像为输入，利用传统图像处理方法提取云概率、灰度、纹理和边缘等多种指标，并通过可视化方式呈现图像分析结果。通过与辐射数据在时间上的对齐，该 GUI 为辐射信号的异常波动提供了直观、可解释的辅助信息。

4) 系统整体集成思路与开发方法

上述三个模块相互衔接，共同构成了完整的多波段天空辐射观测系统：物理传感与自动采集模块负责获取真实、连续的多通道辐射数据；时间序列预测引擎模块对数据进行建模与趋势预测；实时检测与交互分析模块则实现对辐射数据与天空状态的实时展示与预测。通过这一整体设计，本项目完成了从硬件采集到智能分析再到可视化呈现的完整闭环。

在实际开发过程中，我们采用办并行式的方法开发上述三个模块以及各个子模块。最核心基础的物理传感与自动采集模块作为第一优先级进行开发，而其两个子模块——物理传感子模块（太阳灶侧）与自动采集子模块（ $8 \times \text{TEC} + 4 \times \text{ADS1115}$ 侧）可独立并行开发和调试。

与此同时，时间序列预测引擎模块虽然需要真实完整的数据作为基础，但是对于**模型架构搭建子模块**，其模型架构和权重参数配置由于广泛的应用可以事先基于模拟数据集与物理传感与自动采集模块进行并行开发。对于数据预处理子模块，必须获取真实数据集之后才能评判辐射数据的噪声大小与分布情况，从而进行针对性算法处理，因此该模块必须在采集到真实数据并且尝试基于原始数据训练后才能进行开发。

最后优先级模块是实时监测与交互分析模块，作为预测与分析结果直观呈现的辅助模块，本模块并无核心功能，但是具有很强的工程完整性与可操作性，对数据真实性的要求也较高，可以在后期进行开发。

本系统三大模块相对独立，且并发性强，工程可落地性极强，开发流程清晰，自动化程度高且效果可视化性极强，经过如上半并行开发流程后，基本可实现较为完整的天空辐射预测系统雏形。



研究内容及结果分析:

一. 多波段天空辐射的分离与稳定采集

物理传感端的实验装置参见图 2、图 3、图 4。其中图 2 是 8 通道 TEC 阵列传感端的结构示意图，图 3、图 4 分别是物理实验装置的实物图。

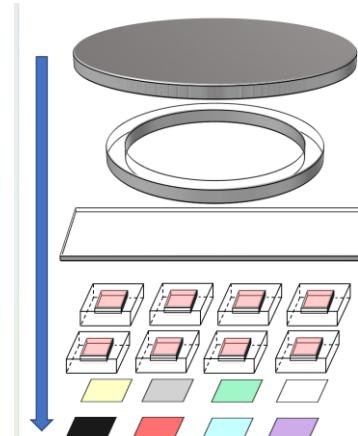


图 2 TEC 阵列传感端结构示意

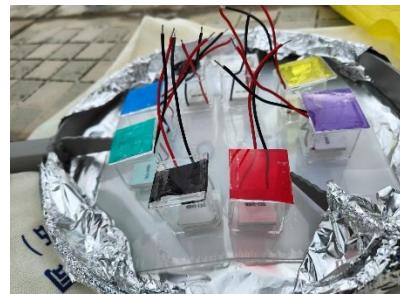


图 3 TEC 阵列实物



图 4 太阳灶实物

为了实现天空辐射的多波段分离，我们使用了 8 个 TEC1-04906 芯片通过滤光片滤光分别采集一个波段范围内的太阳光。8 种滤光片对应的波长范围分别是：

- 1) 紫外片 (Ultraviolet): (320nm, 400nm)
- 2) 透明片 (Transparent): (380nm, 780nm)
- 3) 紫色片 (Violet): (380nm, 450nm)
- 4) 蓝色片 (Blue): (420nm, 500nm)
- 5) 绿色片 (Green): (500nm, 570nm)
- 6) 黄色片 (Yellow): (560nm, 600nm)
- 7) 红色片 (Red): (620nm, 750nm)
- 8) 红外片 (Infrared): (700nm, 1100nm)

在物理实现上，有如下几点需要注意：

1) 完整的冷端恒温且同温控制策略

热电芯片的传感机制是感受正面和背面的温度差，将利用 Seebeck 效应转化为电压差。因此，在测量多通道的电压示数时，必须确保所有热电芯片的冷端温度相同，这样才能用热端受热转化出来的电压衡量辐射强度。为了控制恒温，即消除冷端的太阳光直射，我们将所有热电芯片的冷端与太阳直射用多层锡箔纸隔绝，减少背侧阳光加热冷端，影响测量。为了控制同温，我们将所有热电芯片放置在石英玻璃盒中，热电芯片冷端紧贴盒底，所有盒底全部通过玻璃胶连接到支撑片（亚克力板），我们认为所有盒底的温度都与亚克力板同温。

2) 受热不均问题的减缓

该太阳灶聚焦的焦点并非空间尺寸极小的一个点，其光强呈现空间高斯分

布，因此不同位置的辐射强度是不一样的，因此热效应也是不一样的。事实上，我们在实际测量时确实注意到了这一点，焦点附近的最小光斑的空间尺寸较大，在尺度上与图 3 所示的热电芯片阵列可比。为了解决不同位置温度不同的问题，我们尽量让所有热电芯片环绕最小光斑分布，并且在光轴上将焦点和芯片阵列错开一段距离。例如如图 5 所示，我们可以将热电芯片阵列放置在 A 或者 B 处而非焦点平面处，减少受热不均带来的影响。

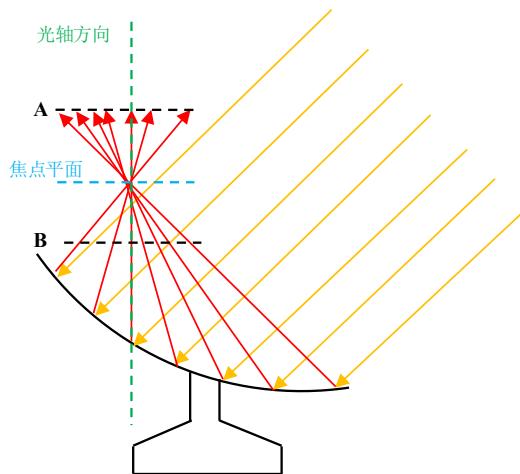


图 5 太阳灶焦点分布与阵列位置

3) 实验安全注意事项

在阳光较为剧烈时，太阳灶焦点位置处的温度较高，经过测量可达 133℃。我们在前期固定 8 个热电芯片时并未采用石英玻璃而是亚克力盒。而亚克力盒的熔点较低，在第一次实验过程中发生了熔化。因此后续实验中我们将亚克力盒更换为熔点更高（可达 1000℃）、透光性更好的石英玻璃，解决了温度过高装置融化以及折射率带来的光线不稳定等问题。

二. 自动化、高频率、高精度的数据采集系统

数据采集系统基于 Raspberry Pi + ADS1115 构建。系统采用 Raspberry Pi5/Pi3B 作为主控，通过 I2C 总线连接 4 个 ADS1115 高精度 ADC 模块，实现 8 路差分电压的同步采集。该系统兼顾自动化程度、采集精度与长期运行稳定性，为后续时间序列建模与预测提供高质量数据基础。采集系统示意图可以参照

(一) 硬件架构与通道配置

ADS1115 是一款 16 位分辨率、支持差分输入的高精度 ADC，具有良好的低噪声特性，适用于微小电压信号的测量。考虑到单个 ADS1115 最多支持两组差分输入，本项目采用 4 块 ADS1115 并联工作，每块 ADC 负责 2 枚 TEC 热电芯片的数据采集，从而实现 8 通道辐射信号的同步测量。

在硬件连接上，通过合理配置 ADS1115 的 ADDR 引脚，将 4 块 ADC 分别映射到 I2C 总线的不同地址（0x48–0x4B），避免地址冲突。每个 ADS1115 均采用差分模式（A0–A1、A2–A3），以抑制共模噪声并提高微弱信号的测量稳定性。

ADS1115 是 16 位 ADC，意味着它能输出从 -32768 到 +32767 的有符号

整数（即 $2^{16} = 65536$ 个离散电平）。ADS1115 可选精度增益、LSB 大小以及传感电压范围参见表 1。

表 1 ADS1115 精度和范围配置

PGA 增益	满量程范围 (FSR)	LSB 大小 (16 位)
0.5	±6.144V	187.5 μV
1	±4.096V	125 μV
2	±2.048 V	62.5μV
4	±1.024 V	31.25μV
8	±0.512 V	15.625μV
16	±0.256 V	7.8125μV

(二) 软件采集框架与自动化控制

采集系统的软件部分基于 Python 开发，运行于 Raspberry Pi 端。通过调用 board、busio 以及 adafruit_ads1x15 等库完成 I2C 总线初始化、ADC 设备配置以及电压数据读取。系统采用模块化设计思路，将设备初始化、数据读取、数据存储与状态显示等功能进行解耦，增强了程序的可维护性和扩展性。

在采集控制逻辑上，系统以固定时间间隔循环执行采样任务。初期采样周期设置为 **10 s/次**，在系统稳定运行后，为进一步提高数据密度和时间分辨率，将采样周期提升至 **5 s/次**。采集过程中，系统为每条数据记录统一添加高精度时间戳（Unix 时间戳与可读时间格式），确保多通道数据在时间轴上的严格对齐。

(三) 多增益测量与高精度电压获取策略

由于热电芯片输出电压幅值较小，且在不同辐射强度下变化范围较大，固定增益配置容易导致量程浪费或信号饱和。针对这一问题，本项目在采集程序中引入**多增益测量机制**。

在每一次采样中，系统针对每个 TEC 通道依次在多个增益设置下进行电压读取（±0.256 V 至 ±4.096 V，即增益 16 至 1），完整记录各增益条件下的测量结果。随后，程序依据“未饱和且精度最高”的原则，从多个增益测量值中自动筛选出最优电压值（我们标记为”Optimal”）及其对应增益，并将其作为该通道的代表性测量结果。例如，测量结果示意可以参照表 2。

表 2 采集系统测量示意

Timestamp	DateTime	TEC1_Gain16	TEC1_Gain8	TEC1_Gain4
1766203261.72352	2025/12/20 12:01:01	-0.000375V	-0.00025V	-0.0005V
TEC1_Gain2	TEC1_Gain1	TEC1_Optimal		
0V	0V	-0.000375V	
TEC8_Gain16	TEC8_Gain8	TEC8_Gain4	TEC8_Optimal	
0.0018125V	0.0018125V	0.0018125V	0.0018125V

(四) 数据存储格式与长期运行机制

采集到的数据以 CSV 格式自动存储于 Raspberry Pi 本地存储中。每条数据记录包含时间戳信息、8 个 TEC 通道在不同增益下的电压值，以及自动选取的最优电压与增益参数，数据结构清晰、可读性强，便于后续批量处理与分析。

为满足长时间、无人实时监测运行的需求，系统进一步通过 systemd 服务机制实现采集程序的后台运行与自动重启。当采集进程异常中断时，系统能够自动拉起服务并继续运行，从而显著提升了数据采集的可靠性与连续性。在实际运行中，该系统成功实现了 24h 的连续稳定采集，未出现数据丢失或系统崩溃问题。

完整的自动数据采集系统连接可以参照图 6。

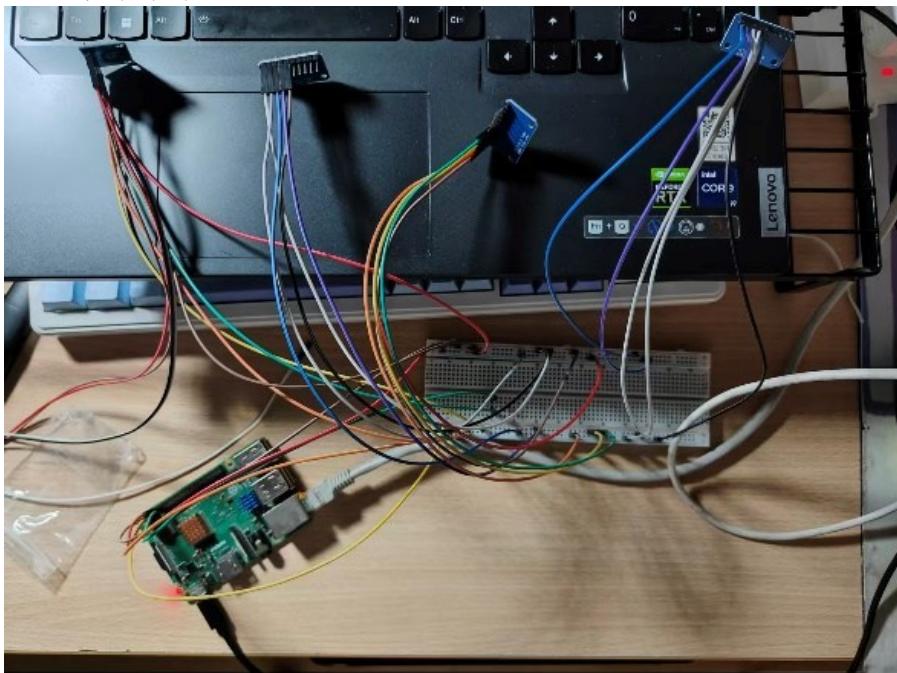


图 6 自动数据采集系统示意图

三. 多通道辐射强度的时间序列预测

(一) 数据降噪算法

在多波段天空辐射观测过程中，热电芯片输出的电压信号幅值较小，且容易受到环境扰动、电磁噪声、采样抖动以及短时云遮挡等因素影响，表现出明显的高频波动与异常跳变，这一点可以在图 7 中清晰的看到，在采集过程的前半段，电压波形中出现了大量的非正常毛刺现象。

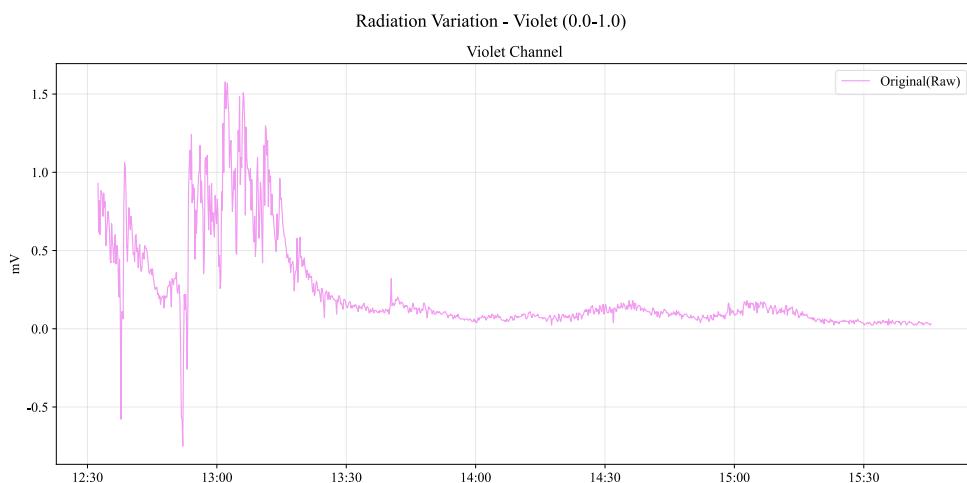


图 7 2025-12-20 Violet 通道采集结果

如果直接将原始数据输入时间序列预测模型，不仅会降低模型的收敛速度，还

可能导致模型过拟合噪声而非真实的物理变化趋势。因此，在模型训练与预测前，对原始数据进行合理的降噪与预处理具有重要意义。

结合实际采集数据的统计特性与物理背景，本项目并未采用单一降噪方法，而是设计并比较了三种具有不同侧重点的数据处理策略，分别为：主动限幅、滑动平均与降采样。

1) 主动限幅算法

主动限幅算法主要用于抑制由采集异常或瞬时干扰引起的极端跳变值。该方法基于相邻时间点辐射强度变化应当连续、平滑这一物理先验，对数据变化幅度设置合理阈值。当某一采样点与前一时刻的差值超过阈值时，认为该点为异常值，并将其限制在允许范围内。

具体方法（Z-score 法）步骤为：我们考虑某一时间窗口 L_{outlier} 范围内的数据，统计平均值 μ 和标准差 σ 。然后我们对每个数据进行评估，设定一个限幅阈值 n ，如果当前数据点 P 不在区间 $[\mu - n\sigma, \mu + n\sigma]$ ，则认为该数据点为异常数据，我们将其利用如下公式(1)进行限幅修改为 P' ：

--	--	--

$$P' = \begin{cases} \mu + n\sigma, & P > \mu + n\sigma \\ \mu - n\sigma, & P < \mu - n\sigma \end{cases} \quad (1)$$

通过控制限幅阈值 n 我们可以控制对数据的修整力度。例如在图 8 中，我们设置了三种不同的阈值，对 2025-12-20 Violet 通道采集结果进行了修正，图中每列的上侧子图表示修正前后，该通道在 0 ~ 10% 时间部分的数据点，下侧子图表示修正的幅度大小 ($|P' - P|$)。

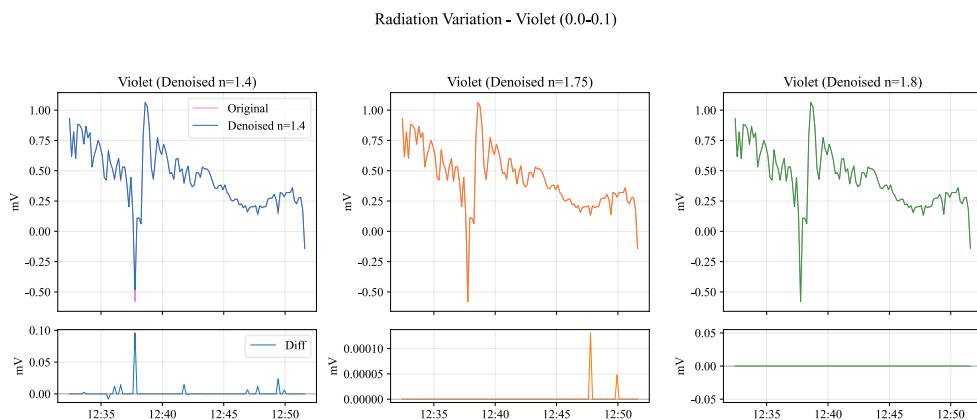


图 8 数据降噪：1.主动限幅示意

值得一提的是，我们在最初考虑时，并未采用公式(1)指定的方法修正异常值，而是使用了公式(2)：

$$P' = \mu, P \notin [\mu - n\sigma, \mu + n\sigma] \quad (2)$$

我们更改为公式(1)的原因可以在图 9 中找到：公式(2)对原始数据点的修改力度可能过大，对原始数据的破坏过多，甚至过多修改原本的物理趋势。因此并非将异常数据点直接修改到均值而是拉到上下边界更加符合物理特性。

总之，主动限幅算法的优势在于能够有效消除突发尖峰噪声，避免异常点对模型训练造成过大影响，同时对数据整体趋势的破坏较小，适合作为第一层防护型降噪手段。

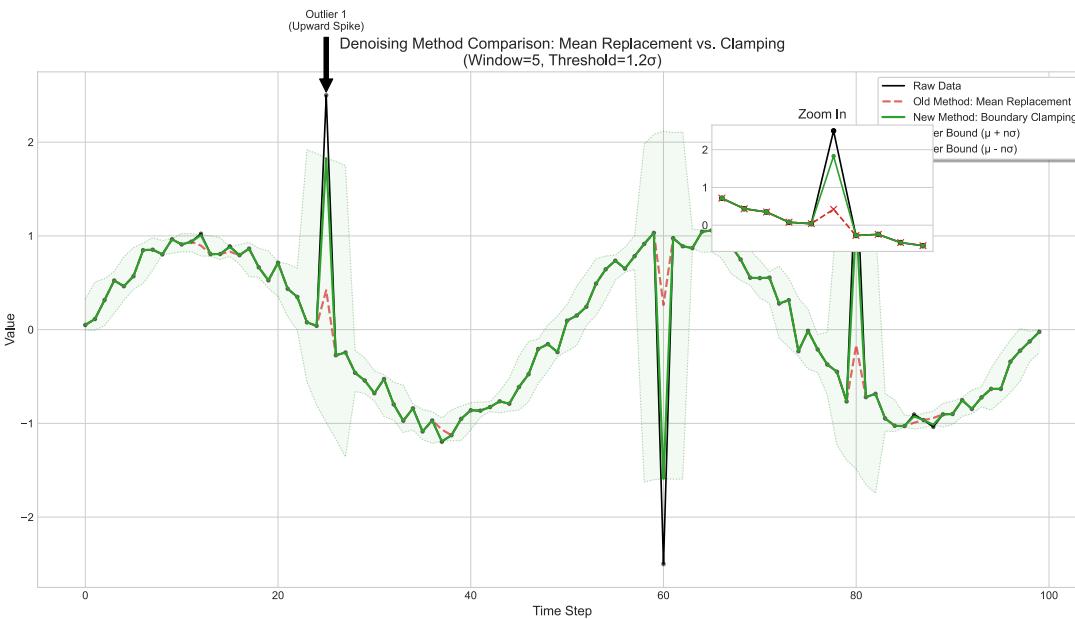


图 9 主动限幅算法的两种策略

2) 滑动平均算法

滑动平均是一种经典的低通滤波方法，通过对时间窗口内的数据进行平均运算，抑制高频噪声成分。对于窗口长度为 L_{smooth} ，其实时间点为 t_k 的滑动平均，其输出可表示为公式(3):

$$x_{t_i} = \frac{1}{L_{\text{smooth}}} \sum_{j=k}^{k+L_{\text{smooth}}-1} x_{t_k}, i = k, k+1, \dots, k+L_{\text{smooth}}-1 \quad (3)$$

我们将这个窗口称为 filter，其长度 L_{smooth} 同样可用于调整降噪力度，图 10 展示了这一过程，布局结构与图 8 相同，同样包含了修改前后的数据对比以及修改力度。

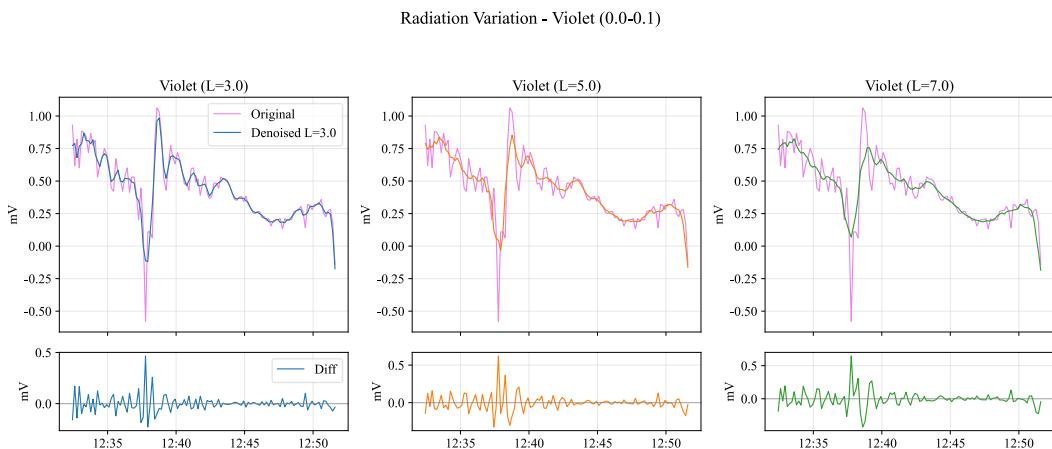


图 10 数据降噪：2.主动限幅示意

可见，相比主动限幅算法，滑动平均算法的修改力度明显较大，因为其无视数据是否在统计意义上偏离标准值，滑动平均算法对任何数据点都会进行修改，而且会利用该数据点附近的信息，最终起到“平滑”的作用。

在本项目中，滑动平均能够显著平滑热电芯片输出中的随机波动，使辐射强度的变化趋势更加清晰，有利于循环神经网络捕捉长期依赖关系。但其缺点在于会引入一定程度的时间延迟，对突变响应不够灵敏，因此窗口长度需要在平滑效果与时间分辨率之间进行权衡。

我们选取 $L_{outlier} = L_{smooth} = 5, n = 1.75$ ，构造了基础降噪配置 **d1**（先进行主动限幅、再进行滑动平均，该配置在后续时间序列预测效果中会再次提到），其降噪效果参见图 11（展示了 0~10% 范围的数据点）和图 12（展示了全部数据点）。

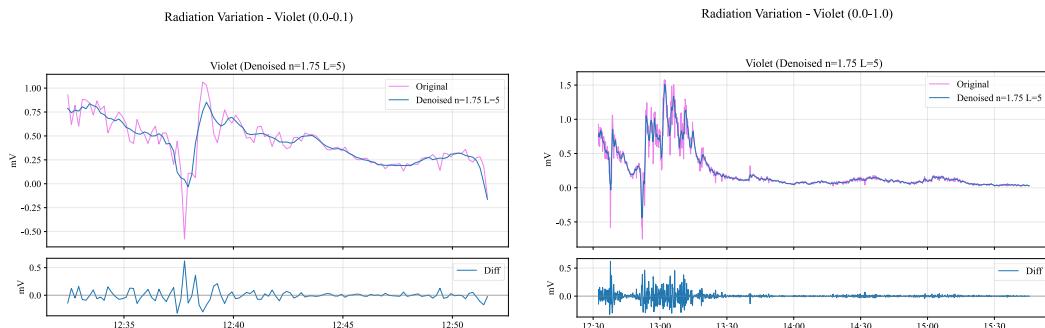


图 11 2025-12-20 Violet 通道数据降噪示意（0~10%）

图 12 2025-12-20 Violet 通道数据降噪示意（0~100%）

3) 降采样算法

采用主动限幅和滑动平均本质上破坏了原始数据，虽然可能得到很好的验证损失，但是真正进行预测时，精度不一定会很高。

考虑到原始采样频率较高，而天空辐射的宏观变化具有一定时间尺度，本项目进一步引入降采样策略，将高频采集数据按照固定步长进行重采样。降采样不仅可以在不修改原始数据的情况下起到平滑作用，还能有效降低数据规模，减少模型训练和推理的计算负担。

降采样算法的方法步骤为：首先选取降采样因子 D ，假设原始数据集相邻两个时间点间隔为 t_d ，那么我们分别以原始数据集中的第 $0, 1, 2, \dots, D-1$ 个数据点为起点，以 D 为相邻点取点步长（对应物理时间为 Dt_d ），构造出 D 份降采样后数据集（所有降采样数据集的总时间点数缩小为原始数据集的 $1/D$ ）。

图 12（从原始数据的第 0 个点开始）和图 13（从原始数据的第 1 个点）分贝展示了 2025-12-20 Violet 通道数据集在降采样因子 $D = 6$ 的情况下，对原始数据进行降采样后的 6 份子集中的前两份。（我们记这种降采样配置为 sub6，在之后的时间序列预测板块会再次提到）

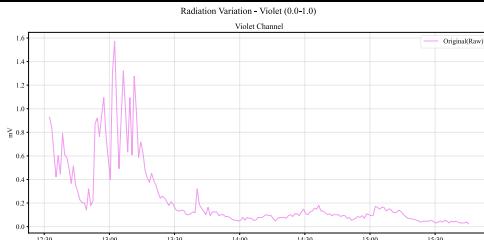


图 13 2025-12-20 Violet 通道降采样数据集 offset0

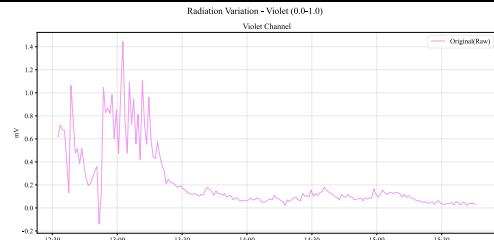


图 14 2025-12-20 Violet 通道降采样数据集 offset1

值得注意的是，虽然降采样算法以扩大相邻两个点的物理时间间隔的核心思想在一定程度上消除了部分高频噪声，但是代价是单份数据集包含的总时间点数减少，可能降低模型进行长时间预测的能力。此外，将一份原始数据集进行降采样后，得到的各个子集之间本身是很像的（当然，局部噪声的存在缓解了这一点），这可能在训练时使得模型看到更多当天的变化趋势，使其倾向于按照当天的数据集变化情况来执行预测。为了缓解这一点，我们必须对所有原始数据集执行 D 相同的降采样，同时控制降采样后的子集数据点个数尽量相同。在实验中，降采样后的数据在保持主要变化趋势的同时，显著提升了模型训练的稳定性，尤其适合用于中长期趋势预测任务。

通过对比不同降噪策略下模型的预测效果，本项目最终验证了 **数据预处理质量对时间序列预测性能具有决定性影响**，合理的降噪与采样策略是提升模型表现的重要前提。

(二) 模型架构理论

针对多通道辐射强度数据具有明显时间序列特性、非线性以及潜在长期依赖关系的特点，本项目选用深度学习中的循环神经网络（Recurrent Neural Network, RNN）及其改进结构作为核心预测模型，重点研究并对比了长短期记忆网络（Long Short-Term Memory, LSTM）与门控循环单元（Gated Recurrent Unit, GRU）两种模型架构。

1) 传统 RNN 的局限性

传统 RNN 通过在网络中引入隐藏状态，使模型能够利用历史信息，其基本更新形式为：

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (4)$$

然而，在处理长时间序列时，RNN 在反向传播过程中容易出现梯度消失或梯度爆炸问题，导致模型难以学习远距离时间步之间的依赖关系。这一缺陷使得传统 RNN 难以胜任天空辐射这种具有明显滞后效应和长期演化特征的数据建模任务。

2) LSTM 模型理论基础

为解决长期依赖问题，LSTM 通过引入 **细胞状态 (Cell State)** 和门控机制，在结构上显著增强了信息的选择性传递能力。LSTM 单元包含遗忘门、输入门和输出门，其核心更新过程见公式(5)：

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f) \\ i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i) \\ \tilde{C} * t &= \tanh(W_c[h * t - 1, x_t] + b_c) \\ C_t &= f_t \cdot C_{t-1} + i_t \cdot \tilde{C} * t \end{aligned} \quad (5)$$

$$o_t = \sigma(W_o[h * t - 1, x_t] + b_o)$$

$$h_t = o_t \cdot \tanh(C_t)$$

其变量定义如下：

t : 时间步索引，对应时间序列中的第 t 个采样点；

x_t : 模型在时间步 t 的输入向量，在本项目中对应多通道热电芯片辐射电压（或经预处理后的辐射强度特征）；

h_t : 时间步 t 的隐藏状态 (Hidden State)，用于表征当前时刻模型对历史信息的综合记忆，并作为输出传递至下一层或下一时间步；

C_t : 时间步 t 的细胞状态 (Cell State)，用于长期信息的存储与传递，是 LSTM 保持长期记忆能力的核心变量；

f_t : 遗忘门 (Forget Gate)，取值范围为 [0, 1]，用于控制上一时刻细胞状态 C_{t-1} 中的信息保留比例；

i_t : 输入门 (Input Gate)，取值范围为 [0, 1]，用于控制当前输入信息写入细胞状态的程度；

\tilde{C}_t : 候选细胞状态 (Candidate Cell State)，表示由当前输入和历史状态共同生成的新信息内容；

o_t : 输出门 (Output Gate)，取值范围为 [0, 1]，用于控制细胞状态对隐藏状态输出的影响；

W_f, W_i, W_c, W_o : 可训练权重矩阵，用于对输入 x_t 与上一时刻隐藏状态 h_{t-1} 进行线性变换；

b_f, b_i, b_c, b_o : 对应各门结构的偏置项；

$\sigma(\cdot)$: Sigmoid 激活函数，用于将门控输出压缩至 [0, 1] 区间，实现“开/关”或“比例控制”的门控效果；

$\tanh(\cdot)$: 双曲正切函数，用于生成取值范围为 [-1, 1] 的候选信息。

也可以参照

在物理意义上，LSTM 通过门控机制实现了对历史辐射信息的选择性记忆与更新，使模型既能保留天空辐射的长期变化趋势，又能抑制短时噪声对预测结果的干扰。

3) GRU 模型理论基础

GRU 是 LSTM 的一种简化变体，将遗忘门和输入门合并为更新门，同时不再显式区分细胞状态和隐藏状态。其核心计算过程参见公式(6)。

其主要变量定义如下：

x_t : 时间步 t 的输入向量，与 LSTM 中含义一致；

h_t : 时间步 t 的隐藏状态，同时承担信息存储与输出的双重功能；

r_t : 重置门 (Reset Gate)，取值范围为 [0, 1]，用于控制历史隐藏状态在生成候选状态时的参与程度；

$$r_t = \sigma(W_r[h_{t-1}, x_t] + b_r)$$

$$z_t = \sigma(W_z[h_{t-1}, x_t] + b_z)$$

$$\tilde{h} * t = \tanh(W[r_t \cdot h * t - 1, x_t] + b)$$

$$h_t = (1 - z_t) \cdot h_{t-1} + z_t \cdot \tilde{h}_t$$
(6)

z_t : 更新门 (Update Gate)，取值范围为 [0, 1]，用于控制历史信息与当前候选

信息之间的权重分配;

\tilde{h}_t : 候选隐藏状态, 表示在当前输入和部分历史信息作用下生成的新状态;

W_r, W_z, W : 可训练权重矩阵;

b_r, b_z, b : 对应的偏置项;

$\sigma(\cdot)$ 、 $\tanh(\cdot)$: 激活函数, 含义与 LSTM 中一致。

GRU 通过更新门实现对长期信息的保留, 通过重置门调节对短期信息的敏感程度, 在保持时间依赖建模能力的同时, 显著降低了模型参数规模和计算复杂度。

这两种模型的基本单元结构也可以参照图 15 和图 16。

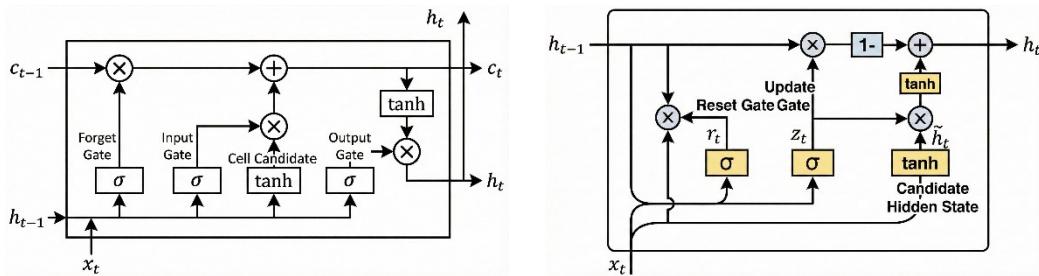


图 16 GRU 基本单元架构

在模型构建过程中, 本项目重点关注隐藏层维度、网络层数以及输入序列长度等关键超参数。隐藏层维度决定了模型的记忆容量, 过小会导致欠拟合, 过大则可能引入过拟合并增加计算负担; 网络层数影响模型对多尺度时间特征的表达能力, 但过深结构会增加训练难度; 序列长度则需要与天空辐射变化的物理时间尺度相匹配 (我们选择输入序列长度为 60, 预测序列长度为 10)。

综合模型复杂度、预测精度与实时性要求, 本项目在 GRU 快速验证的基础上, 最终选用 LSTM 作为主要预测模型, 并在不同数据预处理策略下对其性能进行系统评估。

(三) 时间序列预测

在完成数据降噪算法设计与模型架构确定后, 本项目围绕多通道辐射数据开展了多轮时间序列预测实验。通过逐步引入数据降噪、降采样以及拼接预测 (我们在后面称为 cont) 策略, 对模型预测性能进行系统性对比分析。模型预测性能主要通过均方误差 (Mean Squared Error, MSE) 指标进行定量评估, 也可以通过预测曲线从直观上评判。

在正式介绍我们的训练和预测结果前, 有必要提及我们所采用的数据集以及模型配置:

- 1) 数据集配置: 使用于 2025-11-22, 2025-11-29, 2025-12-14, 2025-12-17, 2025-12-20 采集到的数据作为训练和验证数据集 (数据集的时间跨度均在 3~5h), 利用 2025-12-10 的数据作为测试数据集。
- 2) 四种不同的数据集配置: raw: 原始数据集; d1: 经过了配置为 $L_{outlier} = L_{smooth} = 5, n = 1.75$ 的主动限幅+滑动平均降噪算法降噪后的数据集; sub6: 经过了配置为 $D = 6$ 的降采样后的数据集; d1_sub6: 先经过配置 d1,

- 再经过配置 sub6 进行降噪和降采样后的数据集。在不引起混淆的情况下，我们将对应的训练后的模型也称为 raw, d1, sub6, d1_sub6。
- 3) 选取的预测范围: 在 sub6 数据集中, 选取 2025-12-10-offset1 中的第 77~136 个数据点(约 13:20~14:20 共 1h)作为输入序列, 第 137~146 个数据点(约 14:20~14:30 约 10min)作为待预测序列。如果我们将上述数据点映射到原始数据集, 输入序列时间点分别为: 458~812, 间隔为 6, 共 60 个时间点; 预测序列时间点为: 818~872, 间隔为 6, 共 10 个时间点。在评判 raw 方案和 d1 方案的预测效果时, 我们既可以在 raw/d1 数据集中直接抽取一个片段做预测(此时对应根据 600s 预测后 100s, 我们称这种方案为本征方案), 也可以与 sub6/d1_sub6 预测的片段对齐, 在以下 10 个时间点为输入序列起点执行单步预测: 758~812(间隔为 6), 得到在 raw/d1 方案下时间点为: 818~872(间隔为 6) 的预测值(此时对应单步预测, 能够实现根据 1h 预测后 10min 的效果, 我们称这种方案为 cont 方案)。
 - 4) 模型架构配置: 我们选取 LSTM 作为预测模型, 隐藏层大小为 256, RNN 层数为 2, dropout 比率为 0.2, 学习率 learning rate 初始为 0.001, 连续 10 个 epoch 未改变时乘以 0.5, 权重衰减 weight decay 为 $1e - 5$, 总训练 epoch 轮数为 100

在上述不同配置的数据集下进行训练后, 得到的不同预测结果如下:

1) 基于原始数据的预测 (raw)

首先, 以未经任何降噪与降采样处理的原始辐射数据 (raw) 作为训练集, 构建基线预测模型。该模型直接对高频采样数据进行训练与预测, 然而, 由于原始数据中包含较强的环境噪声与瞬时扰动, 模型在短时预测中容易受到异常点影响(参见图 17, 可见原始数据集的噪声很大, 模型的测效果不佳), 预测曲线在局部区间存在较明显的抖动现象, 对应的 MSE 值为 1.278, 相对较高, 作为后续改进方案的对照基准。

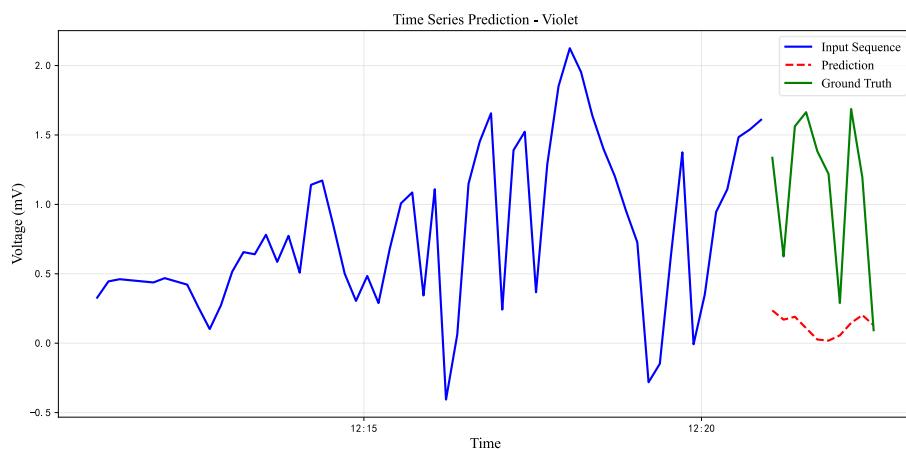


图 17 1210-Violet 通道 12:10~12:25 的 raw 模型预测结果

2) 引入主动限幅与滑动平均的数据预测 (d1)

在 raw 数据基础上, 引入主动限幅与滑动平均相结合的降噪策略, 形成 d1 数据集。该方法有效抑制了单点突变与高频随机噪声, 使辐射时间序列更加平滑, 同时保留了主要物理变化趋势。1210-Violet 通道 12:10~12:25 (与图 17 为同一时间段) 的 d1 模型预测结果见图 18。

基于 d1 数据集重新训练模型后, 预测曲线相较 raw 情况非但没有变化, MSE

还从 1.278 恶化到 2.813，短期预测误差仍维持较高水平。原因可能是因为 d1 更加友好的数据集降低了模型“预测”噪声的能力，从而导致在噪声较大的测试集上表现更差。

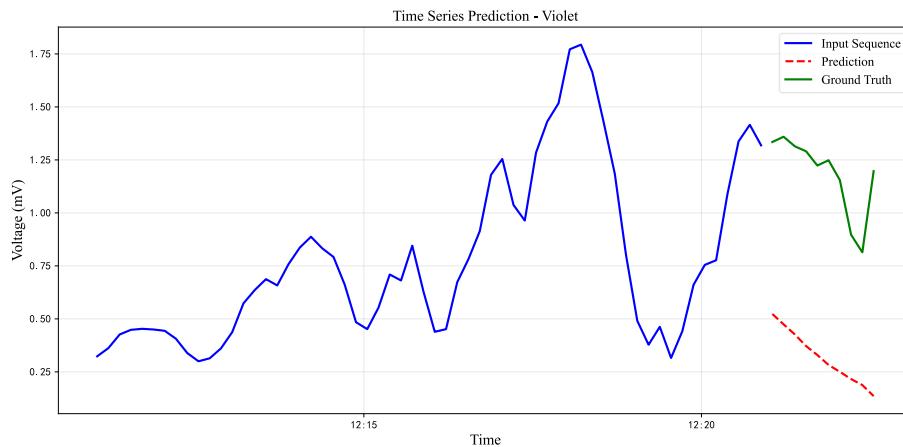


图 18 1210-Violet 通道 12:10~12:25 的 d1 模型预测结果

3) 基于降采样数据的预测 (sub6)

考虑到辐射变化在时间尺度上具有一定平稳性，本项目进一步对数据进行降采样处理 (sub6)，即以固定步长 6 选取原始数据点，从而降低数据冗余度并减少高频噪声影响。

offset1 数据集第 137~146 个数据点（约 14:20~14:30 约 10min）的预测结果参见图 19。直观上，预测结果明显比两种方案 (raw, d1) 准确很多，其 MSE 也降低到 0.004132。

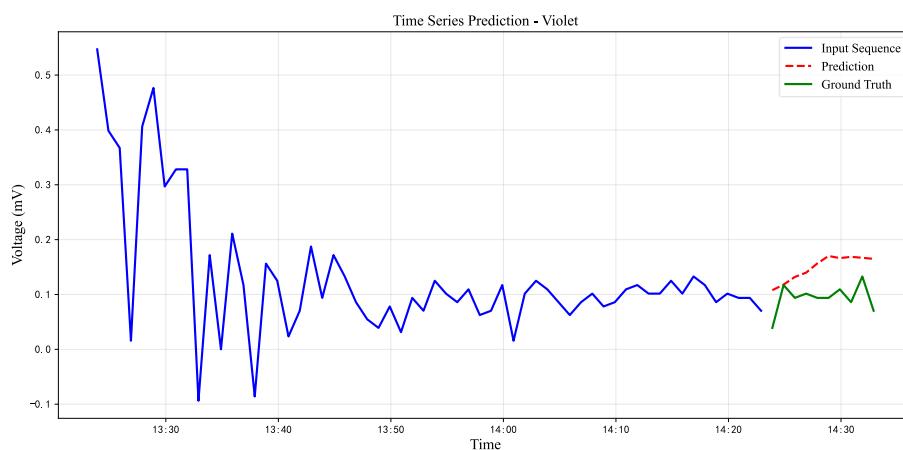


图 19 1210-Violet 通道 14:20~14:30 的 sub6 模型预测结果

在 sub6 数据集上训练的模型，输入序列和预测序列对应的时间间隔更长，有利于模型学习中长期变化规律。实验结果表明，该策略在整体趋势预测方面表现良好，预测曲线更加平滑，但在部分局部细节变化上存在一定程度的滞后现象。其 MSE 相较 raw 和 d1 明显降低。

4) 联合降噪与降采样的数据预测 (d1_sub6)

在前述实验基础上，本项目将降噪 (d1) 与降采样 (sub6) 两种策略进行联合，构建 d1_sub6 数据集。该数据集同时具备噪声抑制与时间尺度压缩的优势。

offset1 数据集第 137~146 个数据点（约 14:20~14:30 约 10min，与图 19 为同一时间段）的预测结果参见图 20。直观上其预测效果与 sub6 模型相近，其

MSE 为 0.004258，两者几乎一致。实验结果显示，sub6 和 d1_sub6 数据集上的模型在预测稳定性和误差控制方面表现优异：预测曲线能够较好地贴合真实辐射变化趋势，同时显著降低预测误差波动，其 MSE 相比 raw 方案和 d1 方案大幅降低，验证了多级数据预处理策略在时间序列预测任务中的有效性。

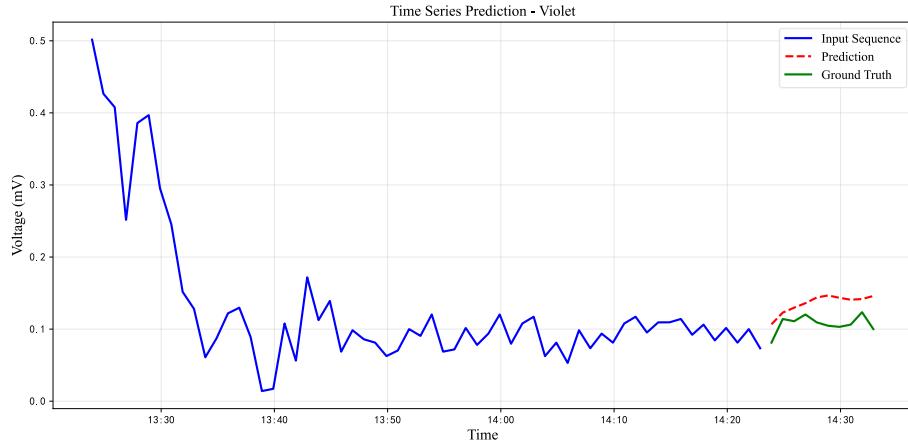


图 20 1210-Violet 通道 14:20~14:30 的 d1_sub6 模型预测结果

5) 未降噪数据集对应模型的拼接预测方案 (raw(cont), d1(cont))

为了探讨 raw 和 d1 是否在长周期上有相比预测局部噪声有更好的预测能力，同时进一步验证模型在真实应用场景中的泛化能力，本项目引入凭借预测 (cont) 方案。该方案不再依赖降采样后的时间轴，而是利用在原始数据上训练的模型，对未参与训练的连续时间点进行逐步单步预测。相关预测结果参见图 21 和图 22，这两者的 MSE 误差分别是 0.000273(raw(cont)) 和 0.002825(d1(cont))，均显著低于 sub6 模型和 d1_sub6 模型，且从预测曲线直观上来看也能够发现预测准确。

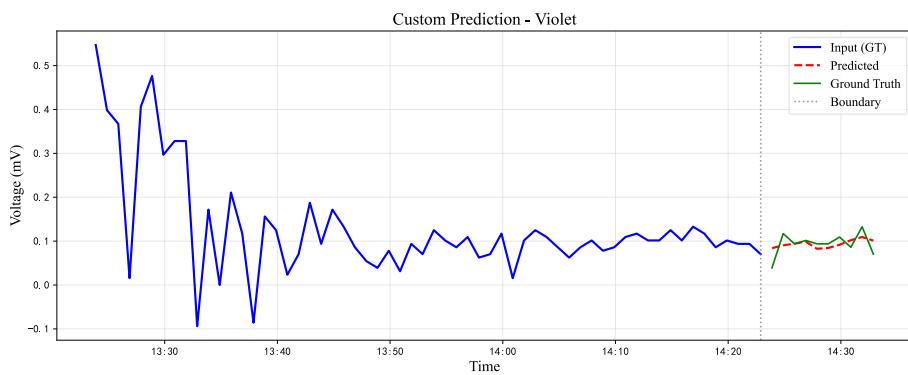


图 21 1210-Violet 通道 14:20~14:30 的 raw(cont) 模型预测结果

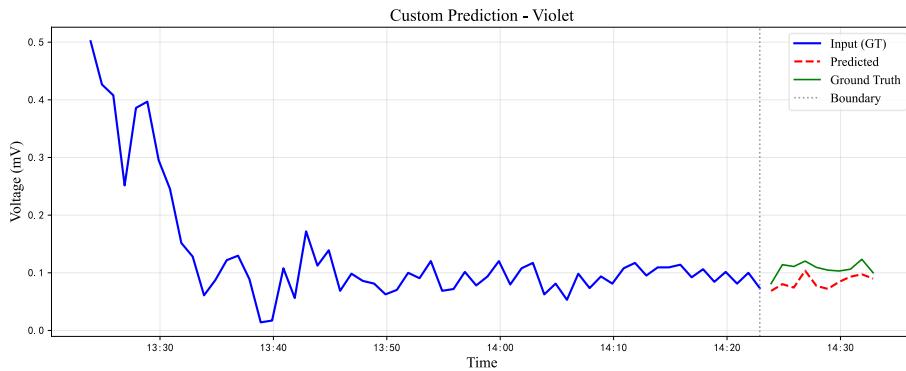


图 22 1210-Violet 通道 14:20~14:30 的 d1(cont) 模型预测结果

确性的提升。说明这两种模型虽然在预测局部变化时表现较差，但是能够捕捉到长周期变化趋势，从而在降采样数据集上也能有不错的预测效果。cont 方案在所有波长通道、1210:1420~1430 的 MSE 误差见表 3 和表 4。

表 3 1210-全通道 14:20~14:30 的 raw cont MSE 预测误差

Channel	Blue	Green	Infrared	Red	Transparent	Ultraviolet	Violet	Yellow
MSE	0.0041	0.0013	0.0017	0.0026	0.0032	0.0003	0.0005	0.0011

表 4 1210-全通道 14:20~14:30 的 d1 cont MSE 预测误差

Channel	Blue	Green	Infrared	Red	Transparent	Ultraviolet	Violet	Yellow
MSE	0.0025	0.0003	0.0004	0.0049	0.0034	0.0003	0.0006	0.0004

我们将 raw(cont) 模型与 sub6 模型、d1(cont) 模型与 d1_sub6 模型的预测效果做纵向对比：

raw(cont) 方案的全通道平均 MSE 误差：0.0019，而 sub6 的全通道 MSE 误差：0.0041；

d1(cont) 方案的全通道平均 MSE 误差：0.0019，而 d1_sub6 的全通道 MSE 误差：0.0043

平均下来，d1(cont) 和 raw(cont) 这两种方案在 MSE 误差上的结果都远优于 sub6, d1_sub6 的结果（从预测曲线上来看相近），原因可能是这种方案执行的是单步预测，而 sub6, d1_sub6 执行的是多步预测，由于 Auto-Regressive 模型的误差会随着预测步数增加而累积，从而导致多步预测的误差更大。

6) 使用 d1_sub6 模型预测 sub6 数据集

我们试图验证主动限幅和滑动平均两种破坏原始数据集的数据增强方式训练出来的模型对原始噪声较大的数据也能有很好的预测能力，因此我们用在数据集 d1_sub6 上训练的模型去预测 sub6-offset1 的数据集，结果比 d1_sub6 模型的预测结果稍微要好一点。MSE: sub6: MSE = 0.004132; sub6 by d1_sub6: MSE = 0.003689

说明我们的两种降噪算法虽然破坏了原始数据，不使用降采样直接预测的话不如原始数据集的结果。但是一旦降采样因子介入后，模型的预测能力会略优于在只用降采样降噪后的数据集上训练的模型的预测能力。

7) 总结

综上所述，多通道辐射强度的时间序列预测性能在很大程度上受数据预处理策略与预测方式的影响。实验结果表明，单纯依赖原始高频数据（raw、d1）进行多步预测时，模型容易受到噪声干扰，预测误差较大；引入降采样（sub6、

d1_sub6) 后，模型能够更好地学习辐射数据的中长期变化规律，预测稳定性和精度显著提升。进一步地，基于原始时间尺度的单步拼接预测（cont）方案在整体 MSE 指标上表现最优，说明模型在捕捉长期变化趋势方面具有较强能力，而多步自回归预测的误差累积是影响预测精度的重要因素。总体来看，合理的数据预处理与预测策略选择，是提升天空辐射时间序列预测性能的关键。

四. 实时辐射监测与预测的可视化系统

五. 天空图像处理系统



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

芯片发电技术基础与应用结题报告

结论：

小组成员贡献：

参考文献：